

Taller 2

2025-10-22

Taller 2

PCA

1. Considerar la base `df_pca.csv`
 - a. Utilizar el siguiente código para elegir un número de componentes principales adecuados.

```
diagPCA=function(pca){  
  print("Summary:")  
  print(summary(pca))  
  print(screeplot(pca,type ="lines"))  
}
```

- b. Completar los siguientes códigos para reconstruir la base reduciendo la dimensión a dicho número utilizando los resultados de `svd` y los resultados de `pca`.

```
recDataRed_pca=function(df,k){  
  n=nrow(____)  
  p=ncol(____)  
  pca_Aux=prcomp(____,center = ____,scale. = ____)  
  z_Aux=pca_Aux$x[,____]  
  v_Aux=pca_Aux$rotation[,____]  
  s_Aux=diag(pca_Aux$____)  
  m_Aux=matrix(pca_Aux$center,nrow = ____,ncol = ____,byrow = T)  
  df_Red=z_Aux%*%t(v_Aux)%*%s_Aux+m_Aux  
  return(df_Red)  
}
```

```
recDataRed_svd=function(df,k){  
  n=nrow(____)  
  p=ncol(____)  
  df_sc=scale(____)  
  m_sc=attr(df_sc,"scaled:center")  
  M_sc=matrix(m_sc,nrow=____,ncol=____,byrow = T)  
  s_sc=attr(df_sc,"scaled:scale")  
  svd_Aux=svd(as.matrix(____))  
  u_Aux=svd_Aux$____[,____]  
  d_Aux=diag(svd_Aux$____[____])  
  v_Aux=svd_Aux$____[,____]  
  df_Red=u_Aux%*%d_Aux%*%t(v_Aux)%*%diag(s_sc)+M_sc  
  return(df_Red)  
}
```

- c. Completar el siguiente código para graficar los datos proyectados en los componentes principales elegidos. Agregar color según alguna otra variable y/o cuán bien representadas están las observaciones en dicha proyección.

```
scorePlot_PCA=function(pca,ax,col.Ch,tit=""){
  sPl=fviz_pca_ind(____,axes = ____ , geom.ind = "point",
                  col.ind = ____ ,title=____,
                  gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"))
  return(sPl)
}
```

- d. Graficar las correlaciones entre variables y componentes principales e identificar qué variable se correlaciona con cada componente (identificar el signo también).

```
corPlot_PCA=function(pca,ax,col.Ch,tit=""){
  cPl=fviz_pca_var(____,axes = ____ ,
                  col.var = ____ ,title=____,
                  gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"))
  return(cPl)
}
```

- e. Realizar un biplot que permite ver tanto representación de observaciones como de variables en simultáneo. Agregar color por alguna variable.

```
biPlot_PCA=function(pca,ax,colI.Ch,colV.Ch,tit=""){
  bPl=fviz_pca_biplot(____,axes=____,
                     geom.ind = "point", col.ind = ____ ,
                     col.var = ____ ,
                     gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),title=____)
  return(bPl)
}
```

Análisis Factorial

2. Considerar la base `df_af.csv`:
 - a. Utilizar el comando `factanal` para elegir un número de factores adecuado. Observar también los autovalores de la matriz de correlación para decidir.
 - b. Completar la siguiente función para representar las correlaciones entre variables y los factores. Identificar las variables correlacionadas con cada factor, considerando el signo.

```
RepFact=function(AnFact,Facts=1:2){
  loadings = as.data.frame(AnFact$____[, Facts])
  LabFacts=paste0("Factor",____)
  GG=ggplot(loadings, aes(x = get(LabFacts[1]), y = get(LabFacts[2]), label = rownames(____))) +
    geom_point() + geom_text(vjust = -0.5) +
    labs(title = "Cargas Factoriales")+
    xlab(LabFacts[1])+ylab(LabFacts[2])+
    theme_bw()+
    xlim(c(-1.2,1.2))+ylim(c(-1.2,1.2))+
    coord_equal()
  return(GG)
}
```

- c. Completar el siguiente código para representar las observaciones proyectadas sobre los factores. Agregar color por factores restantes, si es que los hubiere.

```
RepScore=function(AnFact,Facts=1:2,col=NULL){
  scores = as.data.frame(AnFact$____)
  LabFacts=paste0("Factor",____)
  if(is.null(col)){
    GG=ggplot(scores, aes(x = get(LabFacts[1]), y = get(LabFacts[2]))) +
      geom_point(alpha=0.5)
  }else{
    ColFacts=paste0("Factor",____)
    GG=ggplot(scores, aes(x = get(LabFacts[1]), y = get(LabFacts[2]),color=get(ColFacts))) +
      geom_point(alpha=0.5)+
      labs(color = ____)+
      scale_color_viridis_c()
  }
  GG=GG+
    labs(title = "Scores Factoriales")+
    xlab(LabFacts[1])+ylab(LabFacts[2])+
    theme_bw()+
    coord_equal()
  return(GG)
}
```

CA

3. Considerar la tabla de contingencia Tab_ca.csv. Procesar la tabla completando los siguientes comandos:

```
nR=nrow(____)
nC=ncol(____)
colnames(____)=paste0("A",1:nC)
rownames(____)=paste0("B",1:nR)
```

- a. Completar el siguiente código para calcular la matriz de valores esperados según independencia.

```
EMat=function(Tab){
  nR=nrow(Tab)
  nC=ncol(Tab)
  sR=rowSums(Tab)
  sC=colSums(Tab)
  sT=sum(Tab)
  E=as.matrix(____)%*%t(as.matrix(____))/____
  colnames(E)=paste0("A",1:nC)
  rownames(E)=paste0("B",1:nR)
  return(E)
}
```

- b. Completar el siguiente código para calcular la matriz de desviaciones entre las observaciones y los valores esperados.

```
CMat=function(Tab,E){
  C=(____-____)/sqrt(____)
  return(C)
}
```

c. Completar el siguiente código para elegir un número de ejes adecuado según la varianza

```
pVarEx=function(C){
  svd_Aux=svd(C)
  df_pVE=data.frame("Autovalores"=svd_Aux$___^2)
  df_pVE$Porcentaje_Acumulado=cumsum(df_pVE$Autovalores)*100/sum(df_pVE$Autovalores)
  return(df_pVE)
}
```

d. Completar el siguiente código para representar cada fila y cada columna en el eje correspondiente e identificar combinaciones de filas frecuentes e infrecuentes.

```
rScore=function(C,nRs,k){
  C=as.matrix(C)
  CCt=___%*%t(____)
  eig_Aux=eigen(____)
  A_Aux=diag(1/sqrt(nRs))
  rSc=A_Aux%*%eig_Aux$____[,1:k]%*%diag(sqrt(eig_Aux$____[1:k]))
  rSc=data.frame(rSc)
  names(rSc)=paste0("Eje",1:k)
  rSc$Lab=rownames(C)
  return(rSc)
}

cScore=function(C,nCs,k){
  C=as.matrix(C)
  CtC=t(____)%*%____
  eig_Aux=eigen(____)
  B_Aux=diag(1/sqrt(nCs))
  cSc=B_Aux%*%eig_Aux$____[,1:k]%*%diag(sqrt(eig_Aux$____[1:k]))
  cSc=data.frame(cSc)
  names(cSc)=paste0("Eje",____)
  cSc$Lab=colnames(C)
  return(cSc)
}

RepGraf=function(rS,cS,ejs){
  EjLabs=paste0("Eje",____)
  GG=rS %>%
    ggplot(aes(x=get(EjLabs[1]),y=get(EjLabs[2]))) +
    geom_text(aes(label=____),color="blue") +
    geom_text(data=cS,aes(label=____),color="red") +
    theme_bw() +
    xlab(EjLabs[1])+ylab(EjLabs[2])
  return(GG)
}
```

MDS

4. Considerar la base `df_mds.csv`

a. Completar el siguiente código para proyectar las distancias Euclídeas sobre un número adecuado de componentes.

```
mds_Mink=function(df,k,p=1){
  dMat=dist(___,method = ____,p=p)
  mds_Aux=cmdscale(___,eig = ____ )
  print("Autovalores:")
  print(mds_Aux$eig[___])
  print("Criterio Sólo Positivos:")
  print(cSoloPos(mds_Aux$eig)[___])
  print("Criterio Módulo:")
  print(cAbs(mds_Aux$eig)[___])
  print("Criterio Cuadrados:")
  print(cSq(mds_Aux$eig)[____])
  df_mds=data.frame(mds_Aux$____)
  names(df_mds)=paste0("Dim",___)
  df_mds=cbind.data.frame(df_mds,df)
  return(df_mds)
}
```

b. Completar el siguiente código para graficar las observaciones sobre las componentes elegidas. Agregar color según otras variables para identificar las variables que guían la disimilitud.

```
repGrafMDS=function(df_mds,dims,col.Ch=NULL){
  DimLabs=paste0("Dim",___)
  GG=___ %>%
    ggplot(aes(x=get(DimLabs[1]),y=get(DimLabs[2])))+
    theme_bw()+
    xlab(DimLabs[1])+
    ylab(DimLabs[2])
  if(is.null(col.Ch)){
    GG=GG+
      geom_text(mapping=aes(label=rownames(____)),alpha=0.5)
  }else{
    GG=GG+
      geom_text(mapping=aes(label=rownames(____),color=get(____)),alpha=0.5)+
      scale_color_viridis_c()+
      labs(colour=col.Ch)
  }
  return(GG)
}
```

c. Deducir cómo utilizar los códigos anteriores para repetir las consignas anteriores utilizando la distancia Manhattan con el mismo número de componentes. ¿Qué diferencias observa?